Mini Project 2 (MP2) – Pembersihan Data Terstruktur

Audit, prapemrosesan, dan evaluasi prediksi readmisi dini

Kelompok 4 – Program Doktor Ilmu Komputer, Universitas Brawijaya
Mata kuliah: Topik Analisis Data

Bagus Hardiansyah	267150100111001
Mitra Istiar Wardhana	267150100111023
Harris Imam Fathoni	267150100111026

Status: draf analisis untuk ditinjau kelompok. Angka dan gambar berasal dari keluaran notebook yang diserahkan. Sesuai penugasan, analisis dan interpretasi akhir harus ditulis sendiri oleh kelompok; kontribusi anggota tidak diasumsikan.

1 Tujuan, dataset, dan rancangan eksperimen

Eksperimen menguji apakah paket pembersihan data meningkatkan kinerja *Decision Tree* untuk memprediksi readmisi kurang dari 30 hari. Tujuannya mencakup audit kualitas, perbandingan tiga penanganan data hilang, integrasi kamus, reduksi, dan pipeline yang dapat digunakan ulang. Sumber bukti utama adalah keluaran tersimpan `mp2_colab_.ipynb`; nomor sel pada laporan dihitung dari 1, termasuk sel Markdown.

Dataset UCI Diabetes 130-US Hospitals for Years 1999–2008 berlisensi CC BY 4.0 [1]. Dataset historis memuat kunjungan rawat inap terkait diabetes pada 130 rumah sakit/jaringan pelayanan Amerika Serikat; penelitian asal dijelaskan oleh Strack dkk. [2]. Berkas yang digunakan adalah `diabetic_data.csv` dan `IDS_mapping.csv`. Hasil pembacaan aktual menunjukkan **101.766 kunjungan, 50 kolom, dan 71.518 pasien unik**. Angka 47 fitur pada UCI tidak bertentangan dengan 50 kolom CSV: dua kolom adalah ID dan satu kolom merupakan target.

Satu baris adalah **kunjungan**, bukan satu pasien. Target dibentuk sebagai $y = 1$ jika `readmitted` bernilai `<30`; nilai `NO` dan `>30` menjadi $y = 0$. Terdapat 11.357 label `<30`, 35.545 label `>30`, dan 54.864 label `NO`. Proporsi kelas positif keseluruhan sekitar 11,16%, sehingga accuracy perlu dibaca bersama precision, recall, F1, dan metrik pemeringkatan. Prediksi diposisikan pada saat keluar rumah sakit karena fitur merangkum pelayanan selama perawatan.

Tabel 1: Kelompok variabel dan perlakuan statistik.

Kelompok	Contoh	Tipe dan penggunaan
Identitas	`encounter_id`, `patient_nbr`	Nominal; audit/split, bukan prediktor.
Demografi	`race`, `gender`, `age`	Nominal; usia merupakan interval berurutan, bukan usia eksak.
Penggunaan layanan	Lama rawat, jumlah obat/lab, kunjungan sebelumnya	Numerik diskrit; ringkasan mean, median, kuartil dan sebaran.
Kode pelayanan/diagnosis	Tiga kode ID; `diag_1`–`diag_3`	Nominal; kode numerik bukan besaran fisik.
Obat/pemeriksaan	`insulin`, `A1Cresult`	Kategorik; literal `None` dipertahankan.

Pemisahan pasien. `GroupShuffleSplit` digunakan dua tahap dengan seed 42/43. Fraksi pembagian merujuk pada kelompok pasien [4]; kunjungan pasien yang sama tidak tersebar pada train, validation, dan test.

Subset	Kunjungan	Pasien	Positif (%)
Train	60.878	42.910	11,1075
Validation	20.400	14.304	10,9216
Test	20.488	14.304	11,5531

Pemilihan imputasi dilakukan pada validation; model akhir dilatih ulang pada 81.278 kunjungan train+validation, lalu dievaluasi pada test. Semua langkah yang mempelajari statistik berada di pipeline. Penelitian ini menggunakan satu pembagian; tidak ada interval kepercayaan atau pengujian perbedaan kinerja antarmodel.

2 Audit kualitas dan integrasi

Audit sel 10 menemukan nol duplikat seluruh baris dan nol duplikat `encounter_id`. Sebanyak 16.773 pasien memiliki kunjungan berulang; observasi tersebut dipertahankan karena berbeda dari duplikat catatan. Delapan pemeriksaan rentang logis menghasilkan nol nilai invalid. Hal ini tidak membuktikan kebenaran rekam medis.

Tabel 2: Nilai hilang/invalid pada data keseluruhan dan keputusan pembersihan. Jumlah per kolom dapat tumpang tindih antarbaris.

Variabel	Jumlah	%	Tindakan	Alasan / dampak
`weight`	98.569	96,8585	Buang kolom	Informasi tersedia sangat sedikit.
`medical_specialty`	49.949	49,0822	Buang kolom	Kehilangan tinggi; kompromi informasi.
`payer_code`	40.256	39,5574	Buang kolom	Kehilangan tinggi; kompromi informasi.
`race`	2.273	2,2336	Imputasi modus	Strategi terpilih; 1 kolom.
`gender`	3	0,0029	Invalid ke missing, modus	`Unknown/Invalid`; 1 kolom.
`diag_1`	21	0,0206	Imputasi modus	Kode diagnosis nominal; 1 kolom.
`diag_2`	358	0,3518	Imputasi modus	Sama; 1 kolom.
`diag_3`	1.423	1,3983	Imputasi modus	Sama; 1 kolom.
Dua ID	101.766	100	Keluarkan dari fitur	Identitas tetap untuk audit/split.
Delapan numerik	0 diubah	–	Pertahankan ekstrem	Belum ada bukti kesalahan pencatatan.

Enam dimensi kualitas. Akurasi dinilai terbatas melalui rentang logis; kelengkapan melalui penanda `?`, kosong, dan kategori invalid; konsistensi melalui format/kode serta join tervalidasi; ketepatan waktu dibatasi periode 1999–2008; kepercayaan diperkuat atribusi UCI dan checksum; interpretabilitas ditingkatkan dengan kamus kode dan pemaknaan interval usia. Audit tidak mempunyai rekam medis pembanding untuk memastikan akurasi klinis.

Integrasi. Parser memisahkan tiga bagian `IDS_mapping.csv`, lalu melakukan join *many-to-one*. Sebanyak 8 entri jenis penerimaan, 30 entri disposisi keluar, dan 25 entri asal penerimaan dipakai sebagai kamus. Semua kode pada observasi berhasil dipetakan (`unmapped_n`=0), dan setiap join mempertahankan 101.766 baris. Kode dan deskripsi tidak digunakan bersama sebagai fitur. Tidak ditemukan konflik satuan karena kunci join merupakan kode nominal.

Batas pemenuhan integrasi. Kedua berkas berasal dari paket yang sama: satu tabel observasi dan satu tabel referensi. Ini menunjukkan penggabungan tabel yang valid, tetapi belum membuktikan integrasi *dua sumber independen*. Persyaratan dosen mengenai dua sumber perlu dipastikan; laporan tidak mengklaim sudah memenuhinya sepenuhnya.

2.1 Pola kehilangan dan kehati-hatian inferensi

Pada train, kehilangan `diag_2` dan `diag_3` berkaitan dengan kategori usia dalam tabel chi-square; keluaran $p = 0$ adalah pembulatan/underflow numerik, bukan probabilitas tepat nol. Kehilangan `payer_code` versus usia menghasilkan $\chi^2 = 587{,}329$ dan $p \approx 1{,}10 \times 10^{-120}$. Pola tersebut memberi alasan meninjau asumsi kehilangan acak, tetapi tidak menetapkan MAR/MNAR.

Sebagian tabel memiliki sel harapan kurang dari 5, dan kunjungan dalam pasien tidak independen. Karena itu, nilai p dibaca eksploratif. Baris kehilangan `gender` versus `gender` bersifat sirkular: indikator kehilangan ditentukan oleh kategori itu sendiri. Baris tersebut **tidak digunakan sebagai bukti mekanisme missingness**. Penghapusan tiga kolom juga berpotensi membuang sinyal prediktif; ambang 30% bukan aturan universal.

3 Strategi missing values, outlier, dan redundansi

Tiga strategi menggunakan downstream Decision Tree dan validation yang sama. (1) *Drop rows*: hapus baris train yang memiliki missing pada race, gender, atau diagnosis; missing pada validation tetap diimputasi modus train agar populasi evaluasi identik. (2) *Mode*: modus kategori dan median sebagai fallback numerik. (3) *Model*: ExtraTreesClassifier memprediksi kategori hilang dari delapan fitur numerik, tanpa target readmisi; maksimal 12.000 baris berlabel per kolom, 30 pohon, kedalaman 10, minimum 5 sampel daun.

Tabel 3: Perbandingan pada validation (20.400 kunjungan; sel 20). Waktu hanya satu pengukuran fit dan prediksi.

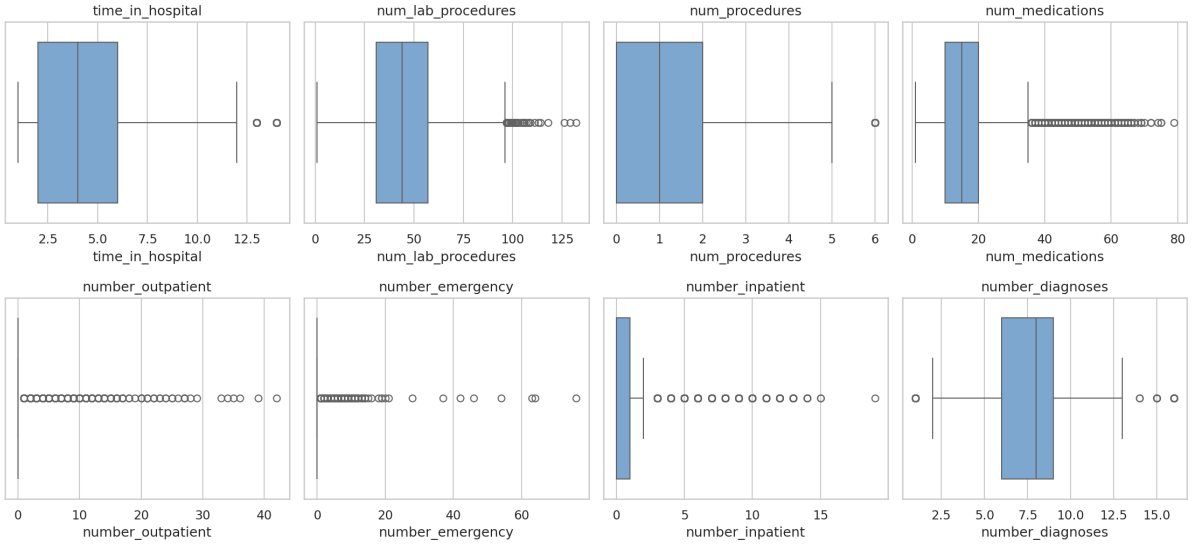
Strategi	Train	Accuracy	F1 positif	F1 makro	Waktu (s)
Drop rows	58.671	0,676814	0,261454	0,527301	5,681
Mode	60.878	0,677500	0,261865	0,527771	5,717
Model	60.878	0,677500	0,261865	0,527771	6,778

Mode dan model memperoleh F1 makro serta F1 positif yang sama pada presisi tersimpan. Pengurutan stabil memilih mode karena muncul lebih dahulu setelah kedua kriteria seri. Modus lebih sederhana dan pada pengukuran ini lebih cepat; tidak ada bukti bahwa imputasi model unggul. Kesamaan metrik tidak berarti semua nilai hasil imputasi identik. Drop rows mengurangi train sebanyak 2.207 kunjungan (sekitar 3,63%).

Deteksi outlier. Batas IQR adalah $Q_1 - 1{,}5\,IQR$ dan $Q_3 + 1{,}5\,IQR$; Z-score menggunakan $|z| > 3$. Seluruh kandidat dipertahankan: ekstrem statistik pada hitungan pelayanan belum tentu kesalahan.

Variabel	Batas atas IQR	Kandidat IQR	$\lvert z\rvert > 3$
Lama rawat	12	1.332	612
Jumlah pemeriksaan lab	96	84	20
Jumlah prosedur	5	2.966	0
Jumlah obat	35	1.556	826
Rawat jalan sebelumnya	0	10.182	852
Kunjungan darurat sebelumnya	0	6.742	577
Rawat inap sebelumnya	2,5	4.152	1.165
Jumlah diagnosis	13,5	164	164

Pada rawat jalan dan darurat, $Q_1 = Q_3 = 0$ membuat semua nilai positif ditandai IQR. Penghapusan otomatis akan menghilangkan riwayat layanan yang berpotensi informatif. Tidak dilakukan capping atau smoothing.



Gambar 1: Boxplot delapan fitur train, diekstrak langsung dari keluaran sel 18 MP2.

Redundansi. Cramer's V untuk `change`–`diabetesMed` adalah 0,5061; jenis–asal penerimaan 0,4008. Asosiasi tidak berarti dua variabel identik. Sebanyak 52,68% sel harapan pasangan kedua di bawah 5 sehingga interpretasi chi-square perlu hati-hati. Pearson dan kovarian dihitung oleh kode; matriks kovarian disimpan ke CSV tetapi tidak ditampilkan dalam notebook, sehingga nilai numeriknya tidak direka dalam laporan ini.

4 Transformasi, reduksi, dan reproduksibilitas

Implementasi memakai `sklearn.Pipeline` [3]. Baseline menghapus ID/target dari fitur, menormalkan penanda invalid, mengisi kategori hilang dengan `Unknown`, lalu melakukan encoding yang diperlukan. Pipeline penuh menambahkan pembuangan tiga kolom, imputasi terpilih, StandardScaler numerik, kategori lama rawat, filter konstanta, dan seleksi fitur.

1. **Standardisasi**: $z = (x - \mu_{train})/\sigma_{train}$. Statistik dipelajari hanya dari subset fit. Setelah strategi dipilih, fit final memakai train+validation.
2. **Encoding**: usia dikodekan ordinal sesuai interval, kategori nominal di-one-hot dengan `min_frequency=20` dan penanganan kategori baru `ignore`. Kode ID nominal diperlakukan sebagai kategori.
3. **Pengelompokan lama rawat**: `stay_band` memakai 1–3, 4–7, 8–14, dan > 14 hari. Kategori terakhir tidak teramati pada dataset ini. Fitur lama rawat asli tetap disertakan.
4. **Pengurangan dimensi**: VarianceThreshold membuang kolom hasil encoding yang konstan, diikuti SelectPercentile berbasis ANOVA F sebesar 75%. Seleksi adalah komponen prediksi, bukan bukti kausal atau pengujian hipotesis klinis.

Tabel 4: Ukuran matriks hasil transformasi dan demonstrasi numerosity (sel 22).

Tahap	Baris	Kolom
Encoded	60.878	944
Nonconstant	60.878	941
Selected 75%	60.878	705
Data tabel sebelum sampling	60.878	48
Sampel bertingkat 25%	15.219	48

Angka 944–941–705 berasal dari penerapan *pipeline final yang telah fit pada train+validation* ke baris train. Angka ini bukan ukuran transformasi yang fit hanya pada train saat pemilihan strategi. Reduksi 239 dari 944 dimensi setara sekitar 25,32%. Sampling mempertahankan proporsi positif 0,111075 menjadi 0,111045. Sampel hanya demonstrasi numerosity, bukan data pelatihan eksperimen utama.

Batas diskretisasi. Lama rawat pada CSV adalah bilangan bulat hari, sehingga implementasi melakukan binning variabel *diskrit*. Persyaratan tugas menyebut atribut kontinu; hal ini perlu dibicarakan dengan dosen atau dilengkapi dengan atribut kontinu yang sah. Mengubah dtype menjadi float tidak membuat pengukuran menjadi kontinu.

Artefak dan penggunaan ulang. `diabetes_clean.parquet` berisi 48 kolom termasuk target dan penanda split, dengan satuan numerik asli. Data ini berasal dari cleaner final (fit train+validation); jangan dipakai untuk mengevaluasi ulang pipeline seolah-olah prapemrosesan belum pernah melihat validation. MP4 secara tepat menggunakan `eda_train_clean.parquet`, yakni 60.878 baris dan 45 fitur yang dibuat oleh cleaner fit train saja. `pipeline.joblib` berhasil dimuat dan diuji memprediksi 10 baris tanpa target, dengan hasil sama seperti objek sebelum penyimpanan.

Lingkungan aktual notebook. Python 3.13.16; NumPy 2.1.3; pandas 2.2.3; SciPy 1.16.3; scikit-learn 1.6.1; Matplotlib 3.10.0; Seaborn 0.13.2; PyArrow 23.0.1; joblib 1.6.0. Semua 13 sel kode MP2 mempunyai execution count berurutan dan tidak menyimpan traceback. Tanggal unduh pada manifest masih berupa isian; tanggal unduh sebenarnya tidak diasumsikan.

5 Evaluasi test dan pembahasan

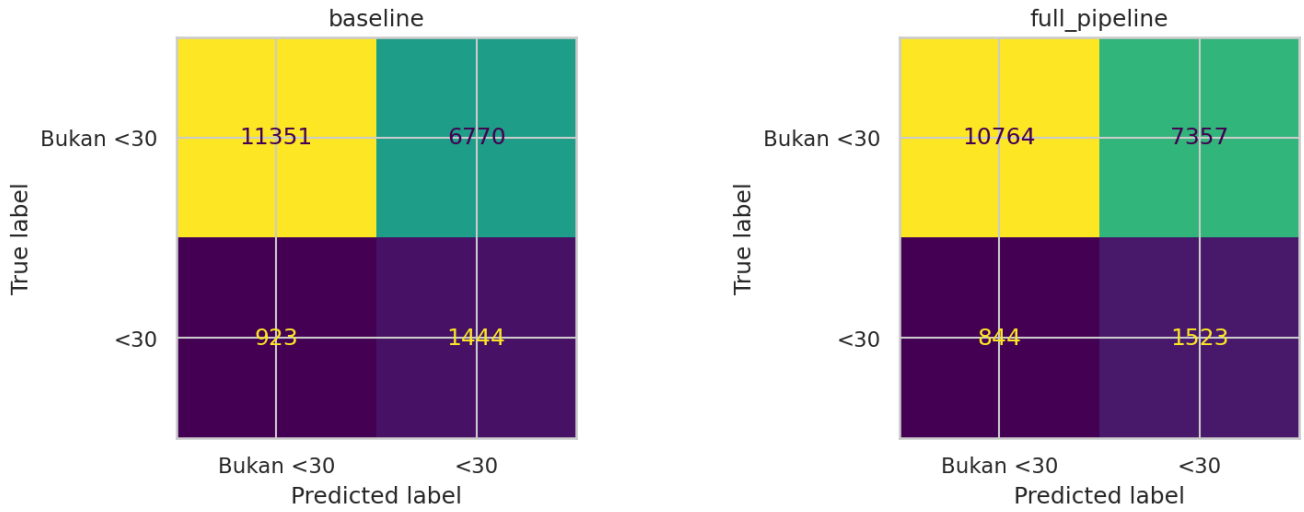
Kedua model memakai Decision Tree dengan `max_depth=6`, `min_samples_leaf=100`, `class_weight=balanced`, seed 42, dan ambang 0,5. Perbandingan menggunakan 20.488 kunjungan test yang sama. Rumus utama:

$$\text{Accuracy} = \frac{TP+TN}{N}, \quad P = \frac{TP}{TP+FP}, \quad R = \frac{TP}{TP+FN}, \quad F1 = \frac{2PR}{P+R}.$$

F1 makro adalah rata-rata F1 kedua kelas; balanced accuracy adalah rata-rata sensitivitas dan spesifisitas.

Tabel 5: Hasil test aktual dari sel 20; tidak dilakukan pemilihan model berdasarkan test.

Metrik	Baseline	Pipeline penuh	Selisih penuh−baseline
Accuracy	0,624512	0,599717	−0, 024795
F1 positif	0,272942	0,270828	−0, 002114
F1 makro	0,509921	0,497485	−0, 012436
Precision positif	0,175797	0,171509	−0, 004288
Recall positif	0,610055	0,643431	+0, 033376
Balanced accuracy	0,618228	0,618719	+0, 000491
ROC-AUC	0,662488	0,662165	−0, 000323
Average precision	0,209263	0,209170	−0, 000093



Gambar 2: Confusion matrix test dari sel 24 MP2: baseline (kiri) dan pipeline penuh (kanan). Baris adalah label aktual, kolom adalah prediksi.

Interpretasi. Pipeline penuh menghasilkan TP 1.523, FN 844, FP 7.357, dan TN 10.764. Baseline menghasilkan TP 1.444, FN 923, FP 6.770, dan TN 11.351. Dengan demikian, tambahan 79 kasus positif terdeteksi disertai tambahan 587 false positive. Recall naik 3,34 poin persentase, tetapi accuracy turun 2,48 poin persentase dan kedua F1 menurun. Tidak tepat menyimpulkan seluruh kualitas prediksi meningkat setelah pembersihan.

Sebagai pembanding aritmetis, selalu menebak negatif memberi accuracy $18.121/20.488 = 88,45\%$, tetapi recall positif nol. Ini bukan hasil pelatihan model tambahan; contoh ini menunjukkan keterbatasan accuracy pada kelas tidak seimbang. Precision sekitar 17% menunjukkan sebagian besar peringatan positif model adalah false positive.

Perbandingan mengubah beberapa komponen sekaligus, sehingga penyebab penurunan tidak dapat dipastikan tanpa ablasi. StandardScaler tidak otomatis membantu pohon keputusan; pembuangan fitur, imputasi, binning, atau seleksi dapat mengubah pemisahan. ROC-AUC dan average precision hampir sama secara deskriptif, tetapi tidak ada uji untuk menyatakan ekuivalensi atau signifikansi. Usulan evaluasi berikutnya harus memakai rencana validasi baru agar test yang telah dibuka tidak menjadi dasar tuning.

6 Kesimpulan, batasan, dan status penugasan

Pipeline berhasil menangani penanda missing, mengintegrasikan kamus tanpa mengubah jumlah baris, menerapkan reduksi dan encoding, serta menyediakan objek prediksi yang dapat digunakan ulang. Modus terpilih pada validation setelah seri dengan imputasi model. Pada test, pipeline penuh menukar peningkatan recall dengan penurunan precision, accuracy, dan F1. Kontribusi utama eksperimen adalah keputusan pembersihan yang dapat ditelusuri dan evaluasi yang memisahkan pasien, bukan klaim peningkatan skor secara universal.

Batas generalisasi. Data historis Amerika Serikat tidak otomatis mewakili pelayanan saat ini atau Indonesia. Label `NO` tidak menjamin tidak terjadi readmisi di fasilitas luar jaringan. Pengulangan kunjungan tetap berpengaruh pada statistik kunjungan meskipun split pasien sudah terpisah. Kasus dengan disposisi meninggal/hospice belum dikeluarkan; definisi populasi berisiko perlu ditinjau sebelum studi lanjutan. Model ini merupakan eksperimen akademik, bukan alat pengambilan keputusan klinis.

Status yang perlu dituntaskan kelompok. Integrasi belum melibatkan dua sumber independen; binning lama rawat belum memenuhi pembacaan literal "atribut kontinu"; tanggal unduh, peran aktual anggota, dan tautan repositori belum diberikan. Keberhasilan menjalankan kode tidak dengan sendirinya berarti seluruh rubrik sudah terpenuhi. Laporan MP2 ini dibatasi enam halaman; penelusuran setiap sel disediakan sebagai bahan kerja terpisah, bukan tambahan halaman laporan wajib.

Pernyataan penggunaan AI. Kode awal, perbaikan notebook, ekstraksi keluaran, dan draf laporan ini dibantu ChatGPT. Pernyataan ini tidak mengklaim bahwa kelompok telah memverifikasi atau menulis ulang seluruh interpretasi. Kelompok perlu memeriksa bukti dan menulis analisis akhirnya sendiri sesuai instruksi mata kuliah. Nama anggota dicantumkan berdasarkan informasi pengguna; pembagian kontribusi belum dilaporkan.

Provenance laporan. Tabel dan gambar diambil dari output notebook yang diunggah, bukan dari hasil eksekusi ulang di lingkungan berbeda. Angka turunan sederhana (selisih metrik, rasio, dan persentase) dihitung dari keluaran tersebut. Grafik asli dicantumkan tanpa mengubah nilai. Dokumen penugasan menjadi dasar batas enam halaman dan catatan pemenuhan rubrik. Sumber dataset dan literatur metodologis tercantum berikut.

Daftar Pustaka

[1] J. Clore, K. Cios, J. DeShazo, dan B. Strack. *Diabetes 130-US Hospitals for Years 1999–2008*. UCI Machine Learning Repository, 2014. Dataset, CC BY 4.0. https://doi.org/10.24432/C5230J.

[2] B. Strack, J. P. DeShazo, C. Gennings, J. L. Olmo, S. Ventura, K. J. Cios, dan J. N. Clore. "Impact of HbA1c Measurement on Hospital Readmission Rates: Analysis of 70,000 Clinical Database Patient Records." *BioMed Research International*, 2014, artikel 781670. https://doi.org/10.1155/2014/781670.

[3] F. Pedregosa dkk. "Scikit-learn: Machine Learning in Python." *Journal of Machine Learning Research*, 12, 2825–2830, 2011. https://jmlr.org/papers/v12/pedregosa11a.html.

[4] Scikit-learn developers. "GroupShuffleSplit." Dokumentasi daring, diakses 26 Oktober 2026. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html.

[5] SciPy community. "scipy.stats.shapiro." Dokumentasi daring, diakses 26 Oktober 2026. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.shapiro.html.

[6] NIST/SEMATECH. *e-Handbook of Statistical Methods*, Bab 1: Exploratory Data Analysis. Diakses 26 Oktober 2026. https://www.itl.nist.gov/div898/handbook/eda/eda.htm.