Mini Project 4 (MP4) – Exploratory Data Analysis

Pola kunjungan dan readmisi dini pada dataset diabetes

Kelompok 4 – Program Doktor Ilmu Komputer, Universitas Brawijaya
Mata kuliah: Topik Analisis Data

Bagus Hardiansyah	267150100111001
Mitra Istiar Wardhana	267150100111023
Harris Imam Fathoni	267150100111026

Status: draf analisis untuk ditinjau kelompok. Angka dan gambar berasal dari keluaran notebook yang diserahkan. Sesuai penugasan, analisis dan interpretasi akhir harus ditulis sendiri oleh kelompok; kontribusi anggota tidak diasumsikan.

1 Ruang lingkup dan tiga pertanyaan analitis

EDA bertujuan memahami struktur data bersih, hubungan antarvariabel, serta implikasinya untuk rancangan pemodelan berikutnya. Pendekatan menggabungkan ringkasan numerik dan visual, sebagaimana kerangka EDA NIST [6]. Sumber utama adalah keluaran tersimpan `mp4_eda_colab_.ipynb`, dengan MP2 sebagai sumber data bersih. Nomor sel dalam laporan dihitung dari 1, termasuk Markdown.

Dataset asal adalah UCI Diabetes 130-US Hospitals for Years 1999–2008, CC BY 4.0 [1]; latar pengumpulan dan penelitian awal dijelaskan oleh Strack dkk. [2]. Analisis ini tidak mereplikasi kohort atau model regresi penelitian asal. Dari keseluruhan 101.766 kunjungan, MP4 hanya menggunakan **60.878 kunjungan train milik 42.910 pasien**, dengan 45 kolom hasil cleaner. Sebanyak 6.762 kunjungan (11,1075%) berlabel readmisi `<30`. Cleaner untuk tabel EDA dipelajari hanya dari train; tabel ini berbeda dari ekspor data bersih keseluruhan yang memakai cleaner final train+validation.

1. **Q1:** Bagaimana proporsi readmisi kurang dari 30 hari berbeda antarinterval usia pada kunjungan train?
2. **Q2:** Bagaimana proporsi readmisi tersebut berubah menurut jumlah rawat inap sebelumnya (0, 1, 2, dan 3 atau lebih)?
3. **Q3:** Bagaimana mean, median, dan IQR lama rawat berbeda antara kunjungan yang diikuti readmisi dini dan kunjungan lainnya?

Target 1 adalah `<30`; target 0 menggabungkan `NO` dan `>30`. Proporsi kelompok dihitung dengan $\widehat{p}_g = n_{g,+}/n_g$, sehingga denominator tiap kelompok harus disertakan. Perbedaan jumlah kunjungan tidak boleh dianggap sebagai perbedaan risiko tanpa memperhatikan denominator.

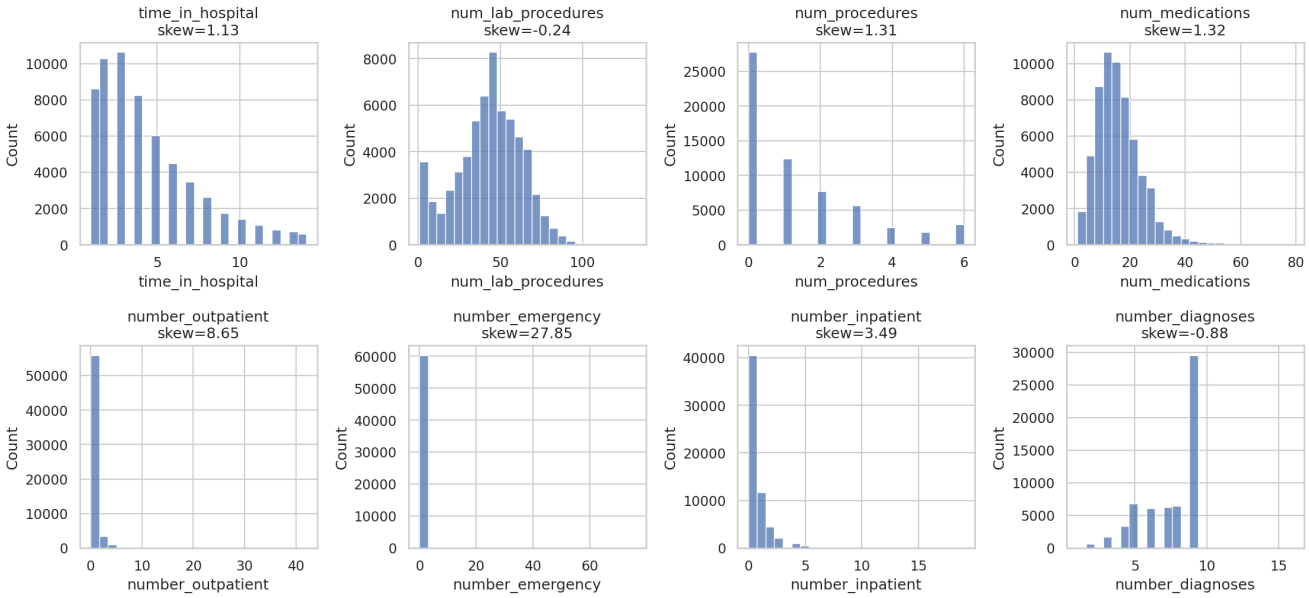
2 Statistik deskriptif numerik

Tabel 1: Statistik train dari sel 9 MP4. Semua variabel memiliki $n = 60.878$. Kuartil dan mean memakai unit asli.

Variabel	Mean	SD	Min	Q_1	Median	Q_3	Maks
Lama rawat (hari)	4,384	2,978	1	2	4	6	14
Pemeriksaan lab	43,102	19,725	1	31	44	57	132
Prosedur	1,343	1,705	0	0	1	2	6
Obat	16,033	8,145	1	10	15	20	79
Rawat jalan sebelumnya	0,373	1,260	0	0	0	0	42
Darurat sebelumnya	0,197	0,972	0	0	0	0	76
Rawat inap sebelumnya	0,628	1,241	0	0	0	1	19
Diagnosis	7,424	1,929	1	6	8	9	16

Mean lama rawat melebihi median, konsisten dengan ekor kanan. Pada rawat jalan dan darurat, $Q_3 = 0$ menunjukkan konsentrasi observasi yang besar pada nol; rentang maksimum tetap lebar. Mean saja tidak mewakili bentuk distribusi tersebut. Jumlah diagnosis memiliki median 8 dan mean 7,424, dengan konsentrasi pada jumlah diagnosis relatif tinggi. Seluruh fitur ini berupa pengukuran diskrit; tidak ada alasan untuk menganggapnya berdistribusi normal hanya karena disimpan numerik.

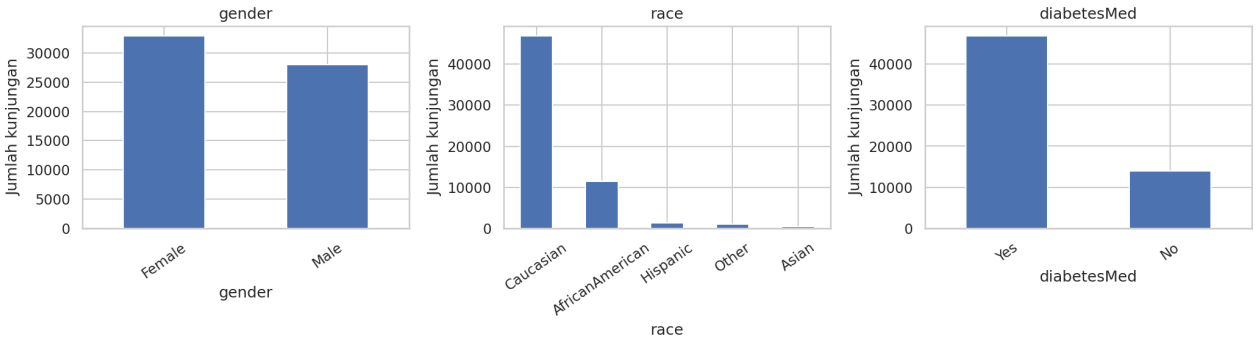
3 Univariat, kategori, dan integritas pembacaan



Gambar 1: Histogram delapan fitur train dari sel 11 MP4. Skala sumbu berbeda antarfitur.

Skewness rawat jalan sebesar 8,6504, darurat 27,8497, dan rawat inap 3,4863 menunjukkan ekor kanan yang panjang. Lama rawat (1,1344), jumlah prosedur (1,3142), dan obat (1,3172) juga condong ke kanan. Pemeriksaan lab sedikit condong ke kiri ($-0,2352$), sedangkan jumlah diagnosis lebih condong ke kiri ($-0,8826$). Lonjakan pada bilangan bulat atau nol tidak cukup untuk menyatakan adanya beberapa subpopulasi atau multimodalitas; hasil histogram juga bergantung pada bin.

Modus kategori adalah Female untuk gender, Caucasian untuk race, interval [70–80) untuk usia, dan Yes untuk `diabetesMed`. Interval [70–80) mencakup 15.594 kunjungan (25,62% train), sedangkan proporsi Caucasian setelah imputasi adalah 77,0015%. Dominasi kategori ini mengharuskan evaluasi antarkelompok dilakukan dengan memperhatikan jumlah observasi, bukan menganggap hasil agregat merata pada semua kelompok.



Gambar 2: Distribusi kategori gender, race, dan penggunaan obat diabetes dari sel 11 MP4.

Catatan penting tentang `NaN`. Tabel modus yang ditampilkan pada sel 9 memberi `NaN` untuk `max_glu_serum` dan `A1Cresult`. Kode membaca data mentah dengan `keep_default_na=False` dan mempertahankan literal `None`; setelah tabel modus ditulis ke CSV, `pd.read_csv` tanpa opsi tersebut menafsirkan kembali teks `None` sebagai missing. Karena itu, output ini merupakan *artefak pembacaan tabel ringkasan*, bukan bukti bahwa pipeline menghilangkan semua kategori pemeriksaan atau gagal mengimputasi.

Modus kedua variabel seharusnya dibaca sebagai kategori literal `None` (tidak ada hasil pemeriksaan dalam kategori dataset), bukan nilai laboratorium normal dan bukan label readmisi. Untuk tampilan laporan/ekspor berikutnya gunakan `pd.read_csv(..., keep_default_na=False)`. Laporan ini mempertahankan makna kategori dan tidak menafsirkan `NaN` tampilan sebagai hasil klinis.

4 Jawaban tiga pertanyaan berdasarkan bukti

Q1 – Usia dan readmisi dini

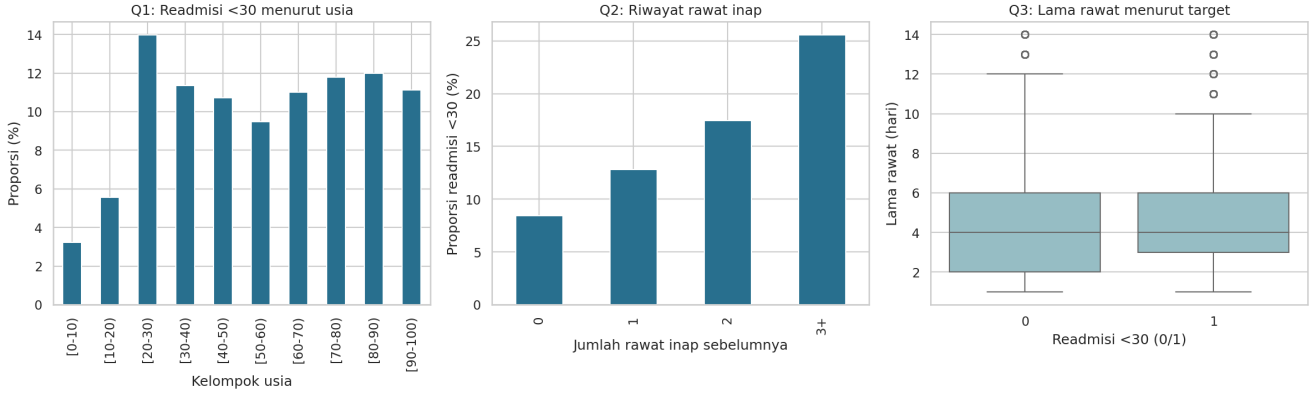
Usia	n	Positif	%
[0–10)	93	3	3,23
[10–20)	413	23	5,57
[20–30)	981	137	13,97
[30–40)	2.275	258	11,34
[40–50)	5.870	630	10,73
[50–60)	10.295	975	9,47
[60–70)	13.349	1.471	11,02
[70–80)	15.594	1.839	11,79
[80–90)	10.317	1.238	12,00
[90–100)	1.691	188	11,12

Q2 – Rawat inap sebelumnya

Riwayat	n	Positif	%
0	40.533	3.416	8,43
1	11.682	1.498	12,82
2	4.511	787	17,45
3+	4.152	1.061	25,55

Q3 – Lama rawat (hari)

Statistik	Bukan < 30	< 30
n	54.116	6.762
Mean	4,3354	4,7720
Median	4	4
SD	2,9723	2,9979
Q_1–Q_3	2–6	3–6



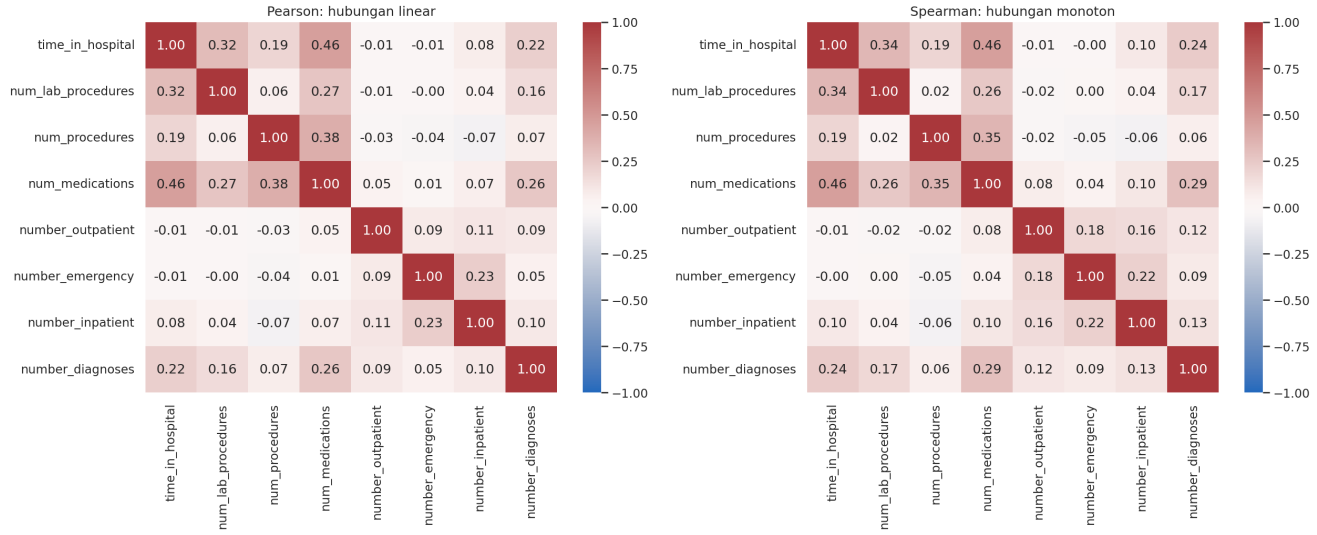
Gambar 3: Visual jawaban Q1–Q3 dari sel 14 MP4; unit analisis seluruh panel adalah kunjungan.

Jawaban Q1. Proporsi tidak meningkat secara monoton dengan usia. Nilai tertinggi yang teramati adalah kelompok [20–30), sebesar 13,97%; kelompok [80–90) sebesar 12,00%. Kelompok [70–80) mempunyai jumlah positif terbesar (1.839) karena denominator besar, bukan proporsi tertinggi. Kelompok anak memiliki sampel sangat kecil; hasilnya kurang stabil. Temuan tidak membuktikan efek usia setelah pengendalian diagnosis atau karakteristik lain.

Jawaban Q2. Terdapat pola naik konsisten pada keempat kategori. Selisih kelompok 3+ dan 0 adalah 17,13 poin persentase, dengan rasio proporsi sekitar 3,03. Rasio ini dihitung dari proporsi kunjungan teramati; bukan estimasi risiko kausal atau efek yang telah disesuaikan. Riwayat rawat inap layak dipertahankan sebagai kandidat prediktor, tetapi hubungan dapat mencerminkan kompleksitas pasien dan pola penggunaan layanan.

Jawaban Q3. Kelas positif mempunyai mean lebih tinggi sekitar 0,437 hari (sekitar 10,48 jam sebagai konversi rata-rata), tetapi median kedua kelas tetap 4 hari. IQR berturut-turut 4 dan 3 hari, dengan rentang kuartil tumpang tindih. Lama rawat saja tidak memisahkan kedua kelas dengan jelas. Data diukur per hari, sehingga konversi mean ke jam bukan presisi pengukuran individual. Tidak ada uji beda atau interval kepercayaan yang mendasari klaim signifikansi.

5 Bivariat, multivariat, dan dampak pembersihan

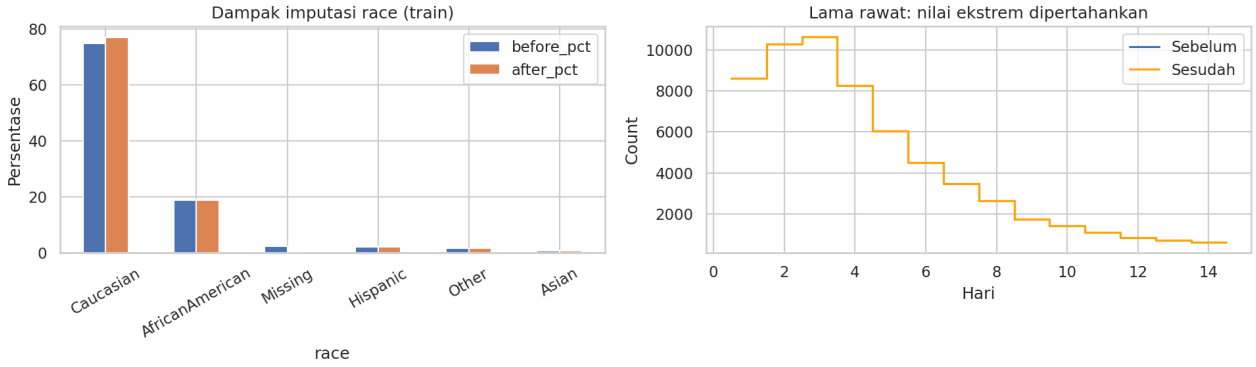


Gambar 4: Heatmap Pearson dan Spearman dari sel 17 MP4; nilai yang dibahas dibulatkan sesuai anotasi grafik.

Hubungan lama rawat dengan jumlah obat terlihat positif pada Pearson maupun Spearman, sekitar 0,46. Prosedur dengan obat sekitar 0,39 pada Pearson dan 0,35 pada Spearman. Lama rawat dengan pemeriksaan lab sekitar 0,32 dan 0,34. Secara deskriptif, tidak ada pasangan numerik dengan korelasi mendekati satu. Hal ini tidak meniadakan ketergantungan nonlinier atau hubungan gabungan beberapa fitur.

Pearson menggambarkan hubungan linear dan lebih sensitif terhadap nilai ekstrem; Spearman memakai peringkat untuk hubungan monoton. Distribusi tidak normal bukan alasan otomatis menolak Pearson sebagai ringkasan deskriptif. Perbandingan kedua ukuran membantu menilai apakah pola yang terlihat bertahan pada representasi peringkat.

Pairplot sel 17 memakai 1.500 kunjungan train, seed 42, dan lima fitur: lama rawat, jumlah obat, pemeriksaan lab, rawat inap sebelumnya, serta jumlah diagnosis. Terdapat tumpang tindih kedua kelas dan garis/pita pada nilai diskrit. Sampel visual ini tidak dapat dipakai untuk mengukur separabilitas populasi secara pasti; grafik lengkap disertakan dalam paket Overleaf dan lampiran bukti.



Gambar 5: Perbandingan sebelum dan sesudah pembersihan dari sel 20 MP4.

Proporsi Caucasian berubah dari 74,7495% menjadi 77,0015%, tepat bertambah sebesar proporsi race yang hilang (2,2520 poin persentase). AfricanAmerican tetap 18,7621%, Hispanic 2,0336%, Other 1,5506%, dan Asian 0,6521%. Modus mengisi seluruh missing dengan kategori mayoritas; kelengkapan bertambah, tetapi komposisi kategori ikut bergeser. Ini bukan bukti perubahan karakteristik pasien yang sebenarnya.

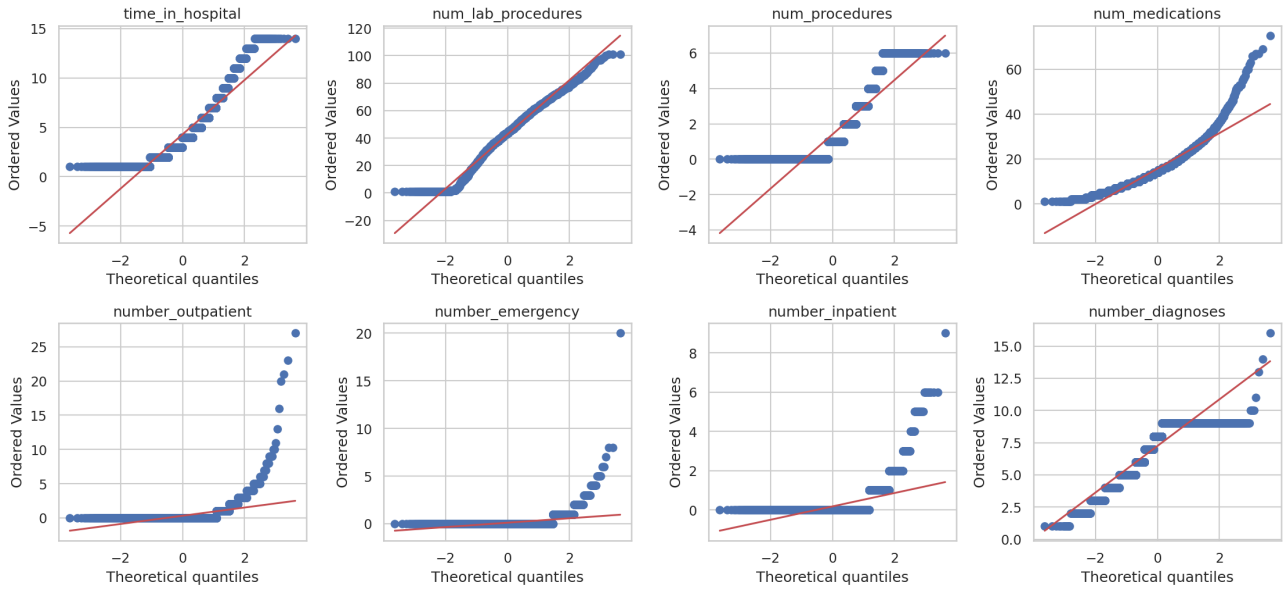
Selisih seluruh statistik deskriptif numerik dan korelasi Pearson sebelum–sesudah adalah nol. Hasil tersebut konsisten dengan keputusan mempertahankan outlier dan tidak mengubah numerik yang sudah lengkap. Nol perubahan bukan kegagalan analisis: tabel EDA tetap memakai unit asli, sementara scaling terjadi pada matriks model. Imputasi kategori tetap perlu diperiksa sebagai sumber bias representasi.

6 Normalitas dan multikolinearitas

Uji Shapiro–Wilk digunakan untuk menilai kesesuaian terhadap distribusi normal [5]. Notebook memilih satu kunjungan per pasien berdasarkan kemunculan pertama dalam urutan train, kemudian mengambil sampel 5.000 pasien, seed 42; ini *bukan klaim kunjungan pertama secara kronologis*. Skewness yang ditampilkan berasal dari seluruh train, berbeda dari sampel uji normalitas.

Tabel 2: Shapiro–Wilk ($n = 5.000$ per fitur) dan VIF pada delapan fitur numerik train, sel 23.

Fitur	W	p	VIF
Lama rawat	0,884373	$1,10 \times 10^{-51}$	1,3632
Pemeriksaan lab	0,983644	$1,29 \times 10^{-23}$	1,1476
Prosedur	0,787435	$9,58 \times 10^{-63}$	1,1929
Obat	0,908652	$1,06 \times 10^{-47}$	1,5294
Rawat jalan	0,276926	$2,50 \times 10^{-88}$	1,0276
Darurat	0,187320	$5,29 \times 10^{-91}$	1,0631
Rawat inap	0,329802	$1,30 \times 10^{-86}$	1,0865
Diagnosis	0,832295	$2,62 \times 10^{-58}$	1,1097



Gambar 6: Q–Q plot sampel satu kunjungan per pasien, diekstrak dari sel 23 MP4.

Seluruh nilai p berada jauh di bawah 0,05; data tidak mendukung bentuk normal eksak. Q–Q plot riwayat layanan menunjukkan penumpukan nol dan penyimpangan besar pada ekor kanan. Namun ukuran sampel besar membuat uji sensitif terhadap deviasi kecil, dan fitur diskrit memang tidak mengikuti normal kontinu secara eksak. Pemeriksaan lab memiliki W paling dekat ke 1, tetapi tetap bukan bukti normalitas.

Decision Tree tidak memerlukan fitur berdistribusi normal. Oleh sebab itu, tidak dilakukan transformasi tambahan hanya untuk membuat hasil Shapiro tidak signifikan. Dalam studi berikutnya dengan model linear atau berbasis jarak, transformasi seperti $\log(1 + x)$ atau scaling robust dapat dibandingkan melalui validasi yang direncanakan; ini rekomendasi, bukan eksperimen yang sudah dilakukan.

VIF dihitung sebagai $\text{VIF}_j = 1/(1 - R_j^2)$, dengan regresi setiap fitur pada tujuh fitur lain dan intercept. Rentang 1,0276–1,5294 tidak menunjukkan multikolinearitas linear kuat pada **delapan fitur numerik yang diuji**. Kesimpulan tidak mencakup seluruh dummy kategori atau fitur turunan. Tidak ada dasar menghapus fitur numerik hanya karena VIF pada hasil ini.

7 Lima insight dan rekomendasi

1. **Riwayat rawat inap paling jelas membedakan proporsi kelompok.** Proporsi meningkat dari 8,43% (0) ke 25,55% (3+). Pertahankan fitur ini dan uji bentuk nonliniernya dalam studi berikutnya; hindari menyebut asosiasi sebagai penyebab readmisi.
2. **Usia tidak menunjukkan pola monoton.** Proporsi [20–30) mencapai 13,97%, sedangkan [70–80) 11,79%. Pertimbangkan pemodelan hubungan usia yang fleksibel serta evaluasi dengan denominator dan ketidakpastian tiap kelompok; kategori kecil jangan disimpulkan secara berlebihan.
3. **Lama rawat hanya memberi pemisahan terbatas.** Mean berbeda 0,437 hari tetapi median sama, 4 hari. Gunakan bersama fitur lain, bukan sebagai ambang tunggal untuk menetapkan readmisi.
4. **Penanganan missing dan outlier membawa konsekuensi berbeda.** Imputasi race menaikkan kategori mayoritas 2,2520 poin persentase; numerik tidak berubah. Pada evaluasi baru, bandingkan indikator missing/strategi alternatif dan audit performa antarkelompok. Jangan menghapus semua nilai di atas batas IQR nol.
5. **Model perlu menangani sebaran dan ketidakseimbangan, bukan mengejar normalitas.** Riwayat layanan sangat skew, VIF numerik rendah, dan kelas positif train 11,11%. Gunakan metrik kelas positif, PR/ROC, kalibrasi serta evaluasi berbasis pasien; transformasi tambahan hanya diuji dalam skema validasi baru.

Kesimpulan. EDA menunjukkan hubungan deskriptif riwayat layanan dengan readmisi dini, heterogenitas menurut usia, serta tumpang tindih lama rawat antarkelas. Pembersihan memperbaiki kelengkapan kategori tetapi mengubah komposisi race. Kualitas data dan kecocokan model perlu dinilai terpisah: MP2 memperlihatkan recall meningkat, sementara accuracy dan F1 sedikit menurun.

Batasan dan integritas. Seluruh ringkasan merupakan tingkat kunjungan dan dapat memberi bobot lebih besar kepada pasien yang sering dirawat. Tidak dilakukan analisis kausal, interval kepercayaan, atau validasi eksternal. Data historis, cakupan jaringan, dan belum dikeluarkannya meninggal/hospice membatasi interpretasi. EDA tidak digunakan untuk mengubah model setelah test MP2 terbuka. Seluruh 11 sel kode MP4 menyimpan eksekusi berurutan tanpa traceback; sel 26 menyimpan poster, tetapi video presentasi dan kontribusi anggota tidak tercakup dalam bukti yang diberikan.

Pernyataan AI. Draf laporan, ringkasan angka, dan bantuan kode menggunakan ChatGPT. Kelompok harus meninjau bukti dan menulis analisis final sendiri sesuai tugas. Sel bertanda “TULIS SENDIRI” masih berupa panduan pada notebook yang diberikan; dokumen ini tidak mengklaim bahwa isian tersebut sudah ditulis oleh kelompok.

Daftar Pustaka

[1] J. Clore, K. Cios, J. DeShazo, dan B. Strack. *Diabetes 130-US Hospitals for Years 1999–2008*. UCI Machine Learning Repository, 2014. Dataset, CC BY 4.0. `https://doi.org/10.24432/C5230J`.

[2] B. Strack, J. P. DeShazo, C. Gennings, J. L. Olmo, S. Ventura, K. J. Cios, dan J. N. Clore. “Impact of HbA1c Measurement on Hospital Readmission Rates: Analysis of 70,000 Clinical Database Patient Records.” *BioMed Research International*, 2014, artikel 781670. `https://doi.org/10.1155/2014/781670`.

[3] F. Pedregosa dkk. “Scikit-learn: Machine Learning in Python.” *Journal of Machine Learning Research*, 12, 2825–2830, 2011. `https://jmlr.org/papers/v12/pedregosa11a.html`.

[4] Scikit-learn developers. “GroupShuffleSplit.” Dokumentasi daring, diakses 26 Oktober 2026. `https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html`.

[5] SciPy community. “scipy.stats.shapiro.” Dokumentasi daring, diakses 26 Oktober 2026. `https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.shapiro.html`.

[6] NIST/SEMATECH. *e-Handbook of Statistical Methods*, Bab 1: Exploratory Data Analysis. Diakses 26 Oktober 2026. `https://www.itl.nist.gov/div898/handbook/eda/eda.htm`.